



张灏宇

北京大学未来技术学院，北京

Tel: 15102351080 Email: hauserzhang@pku.edu.cn

性别：男 生日：1999 年 3 月 1 日

政治面貌：共产党员 籍贯：重庆市綦江区

出生地：重庆市渝中区

现住址：北京市海淀区颐和园路五号北京大学



教育经历

09/2021~06/2026 北京大学，未来技术学院，生物医学人工智能方向全日制博士研究生（5 年制）

【相关课程】：医学人工智能（A+）、网络表示学习（A）、统计与数据分析（A+）、神经网络与深度学习（A）、深度学习：算法与应用（A-）

09/2017~06/2021 北京大学，工学院，生物医学工程系全日制本科生，GPA:3.73/4.0 (排名：1/15)

【相关课程】：数学分析（94）、数据结构与算法（92）、概率与数理统计（91）、计算方法（89）

09/2018~06/2021 北京大学，计算机学院，计算机科学与技术专业双学位

【相关课程】：编译技术（95）、操作系统（85）、python 程序设计（97）

09/2014~06/2017 重庆市第一中学校，物理竞赛班

获得奖项

09/2021~09/2022 北京大学工学院学术新星

09/2020~09/2021 北京市优秀毕业生、北京大学优秀毕业生

09/2019~09/2020 全国大学生数学竞赛二等奖、北京大学优秀科研奖

09/2018~09/2019 “夏受虞-黄玉岑”本科实习奖学金、北京大学三好学生

09/2017~09/2018 北京大学社会工作奖、北京大学五四奖学金

竞赛经历

08/2021~12/2021 滴滴 SIGSPATIAL GISCUP 比赛，第二名

参加滴滴举办的 SIGSPATIAL GISCUP 在线竞赛。利用深度学习算法开发了网约车预计到达时间预测模型，最终获得比赛第（2/1000）名。

11/2019~11/2019 第十一届全国大学生数学竞赛，二等奖

09/2014~06/2017 第三十三届全国中学生物理竞赛国家决赛，银牌

获得省级一等奖、国家决赛银牌，重庆市第二名。获得北京大学降一本线录取。

实习经历

07/2025~至今 华为技术有限公司，2012 实验室中央软件院，OS 内核实验室

我在实习期间参与开发算法-系统混合优化的 MoE 大模型端侧部署解决方案。我们提出了缓存亲和性约束条件来突破 MoE 模型运行时缓存命中率的理论上限。通过跨模型架构、LoRA 微调以及缓存策略的优化，实现端到端的 MoE 模型端侧推理部署。实验结果表明该方案能够在不损失 MoE 模型精度和吞吐的前提下，显著降低模型在端侧设备上推理时的内存消耗，满足日益增长的端侧大模型部署需求。该工作目前已完成专利申请，我目前正负责撰写论文投稿中。在本项目中我掌握了 LoRA 微调大模型的全过程、学习掌握了 MoE 模型推理加速的各类方法（专家量化、剪枝、卸载等）、阅读了主流推理引擎 llama.cpp 的源码并掌握其原理。

科研经历

09/2021~至今 北京大学，博士研究生

主要从事生物信息学和深度学习在微生物基因组学上的应用方向的研究。已发表和在投的论文如下：

- (1) VFormer: predicting virulence factor functions at the network level by integrating protein language model embedding with host-microbe protein-protein interaction.
一作，应用 Graph-Transformer 架构和分层多标签分类网络，基于蛋白质语言模型和细菌-宿主蛋白互作网络预测细菌毒力蛋白及其功能类别，成稿阶段。
- (2) KuafuPrimer: Machine learning facilitates the design of 16S rRNA gene primers with minimal amplification bias in bacterial communities.

一作，利用 1D-Unet 的深度学习模型实现微生物 16S rRNA 基因可变、保守区域的准确划分，并基于此模型开发了菌群特异性最优引物设计算法，在投。

- (3) Qiu, S., **Zhang, H.**, Zhou, F., Huang, H., Cheng, H. & Wang, X. In vivo imaging of neuronal mitochondrial Ca^{2+} transients with two-photon microscopy in awake mice. *Mitochondrial Communications*. Online ahead of print (2025).

共同一作，基于深度神经网络开发了对双光子显微镜神经元线粒体 Ca^{2+} 信号在体成像数据进行线粒体分割、钙信号检测、异常识别的算法。

- (4) Gan, Y., **Zhang, H.**, & Wang, M. (2021, November). Travel Time Estimation Based on Neural Network with Auxiliary Loss. In *Proceedings of the 29th International Conference on Advances in Geographic Information Systems* (pp. 642-645).

共同一作，开发了宽度-深度双向循环神经网络结合辅助损失函数模型 WDDRA，用于预测网约车预计到达时间，获得 SIGSPATIAL GISCUP 竞赛第二名。

- (5) Luo, Q., ..., **Zhang, H.**, ... & Xiao, Y. (2025). Genomic epidemiology and phylodynamics of *Acinetobacter baumannii* bloodstream isolates in China. *Nature Communications*, 16(1), 3536.

四作，对中国 76 家医院的 1506 株鲍曼不动杆菌血流感染菌株的全基因组测序分析，发表于 *Nature Communications*（中科院 1 区，IF=14.7）。

- (6) Jiang, X., ..., **Zhang, H.**, ... & Zhu, H. (2022). Global meta-analysis of airborne bacterial communities and associations with anthropogenic activities. *Environmental Science & Technology*, 56(14), 9891-9902.

四作，对于全球空气微生物组的荟萃分析，量化了微生物多样性与人为活动的关联及对人体健康的影响，发表于 *Environmental Science & Technology*（中科院 1 区，IF=10.9）。

- (7) 专利（申请中，初审通过）：基于深度学习的 16S rRNA 基因测序引物设计方法及系统。

- (8) 专利（申请中，初审通过）：人工微生物群落从头设计方法、装置、电子设备及可读存储介质。

组织经历

05/2018~05/2019 北京大学工学院学生会，外联部部长

09/2020~09/2022 北京大学未来技术学院生医班，班长

09/2020~06/2023 北京大学工学院足球队，队长

09/2020~至今 北京大学普通生足球队，队员

技能和兴趣

技能：熟悉 python, C++, R, 了解 Matlab, Perl 等编程语言；熟悉 Pytorch、PyG 等深度学习架构，具有开发 GNN、Graph-transformer、CNN、LSTM、U-Net 等多种网络架构的经验，了解 BERT、Transformer、MoE 等大语言模型 (LLM) 的原理，具有微调 4B、16B 开源 MoE 模型经验，熟悉大语言模型在小分子、蛋白质以及核酸领域的应用。熟悉 DeepSpeed、llama.cpp 等主流大模型推理训练框架。

兴趣：涉猎广泛、学习能力强，喜爱数理、统计学和编程。本科期间因为兴趣选修了计算机科学与技术双学位，并在算法设计系列课程、深度学习与机器学习系列课程、并行与分布式计算、编译技术等专业课程中成绩突出；在统计推断、统计与数据分析、数学分析以及各类大学物理课程中成绩优异；因为兴趣旁听过物理学专业研究生课程广义相对论。

英语水平：CET4；CET6；GRE 总分 324 (Verbal155+Quantitative169+Writing3.0)；TOEFL 总分 94。